

**Technická univerzita v Košiciach
Fakulta elektrotechniky a informatiky**

**Implementácia výpočtov na hrane (MEC)
s využitím robotov Rosmaster R2**

Diplomová práca

**Technická univerzita v Košiciach
Fakulta elektrotechniky a informatiky**

**Implementácia výpočtov na hrane (MEC)
s využitím robotov Rosmaster R2**

Diplomová práca

Študijný program: Počítačové siete
Študijný odbor: Informatika
Školiace pracovisko: Katedra elektroniky a multimediálnych telekomunikácií (KEaMT)
Školiteľ: doc. Ing. Gabriel Bugár, PhD.

Košice 2025

Bc. Igor Gombala

Abstrakt v SJ

Abstrakt v slovenčine.

Kľúčové slová v SJ

L^AT_EX,

Abstrakt v AJ

Abstract in English.

Kľúčové slová v AJ

L^AT_EX,

Bibliografická citácia

GOMBALA, Igor. *Implementácia výpočtov na hrane (MEC) s využitím robotov Ros-master R2*. Košice: Technická univerzita v Košiciach, Fakulta elektrotechniky a informatiky, 2025. 7s. Vedúci práce: doc. Ing. Gabriel Bugár, PhD.

Tu vložte zadávací list pomocou príkazu
`\thesisspec{cesta/k/suboru/so/zadavacim.listom}`
v preamble dokumentu.

Kópiu zadávacieho listu skenujte čiernobielo (v odtieňoch sivej) na 200 až 300
DPI! Nezabudnite do jednej práce vložiť originál zadávacieho listu!

Čestné vyhlásenie

Vyhlasujem, že som záverečnú prácu vypracoval(a) samostatne s použitím uvedenej odbornej literatúry.

Podakovanie

Na tomto mieste by som rád poďakoval svojmu vedúcemu práce za jeho čas a odborné vedenie počas riešenia mojej záverečnej práce. Rovnako by som sa rád poďakoval svojim rodičom a priateľom za ich podporu a povzbudzovanie počas celého môjho štúdia.

Obsah

| | | |
|----------|-----------------------------------|----------|
| 1 | Úvod | 1 |
| 2 | Analytická časť | 2 |
| 2.1 | Klasifikácia objektov | 2 |
| 2.2 | Detekcia objektov | 2 |
| 2.3 | YOLO | 3 |
| 3 | Vyhodnotenie | 5 |
| 4 | Záver | 6 |
| | Zoznam použitej literatúry | 7 |

Zoznam obrázkov

| | | |
|-----|---|---|
| 2.1 | Zrežazenie klasifikácie objektov | 2 |
| 2.2 | Zrežazenie detekcie objektov | 3 |
| 2.3 | Porovnanie s ďalšími známymi metódami pokiaľ ide o kompromi- sy latencie-presnosť (vľavo) a FLOP-presnosť (vpravo) | 4 |

1 Úvod


Formulácia úlohy

1. Štúdium teoretických východísk a analýza výsledkov predchádzajúcich prác. Oboznámenie sa s konceptom Multi-access Edge Computing (MEC) a decentralizovaných výpočtových sietí. Detailne preskúma výsledky predchádzajúcich diplomových prác, ktoré sa venovali optimalizácii výpočtov na hrane a bezpečnostným aspektom v 5G a 6G sieťach.
2. Návrh a realizácia MEC siete v laboratóriu počítačových sietí. Cieľom je vytvoriť funkčné laboratórne prostredie pre MEC sieť, ktorá bude umožňovať efektívne využívanie hraničných výpočtov. Študent navrhne architektúru siete, konfiguráciu zariadení a integráciu výpočtových uzlov na hrane.
3. Implementácia výpočtov na hrane MEC s využitím robotov Rosmaster R2 (vozidlá autonómnej mobility - robot so štruktúrou Ackermann podporujúci operačný systém ROS, ROS2 pre použitie AI). Návrh a zrealizovanie riešenia umožňujúce robotom Rosmaster R2 využívať výpočtový výkon MEC siete. Riešenie bude optimalizované na zníženie latencie, minimalizáciu spotreby energie a efektívne rozdelenie výpočtovej záťaže medzi hraničné a cloudové uzly.
4. Testovanie a hodnotenie efektivity navrhnutého riešenia. Súčasťou budú merania výkonnosti siete a analýza parametrov, ako sú latencia, šírka pásma, výpočtový výkon a spotreba energie. Overenie stability systému a jeho schopnosť zvládnuť rôzne typy pracovných záťaží.
5. Vypracovanie dokumentácie a odporúčaní pre ďalší vývoj. Na záver bude zdokumentovaný celý proces návrhu, implementácie a testovania. Študent vypracuje odporúčania pre ďalší vývoj a optimalizáciu MEC sietí v spojení s autonómnymi robotmi.

2 Analytická časť

2.1 Klasifikácia objektov

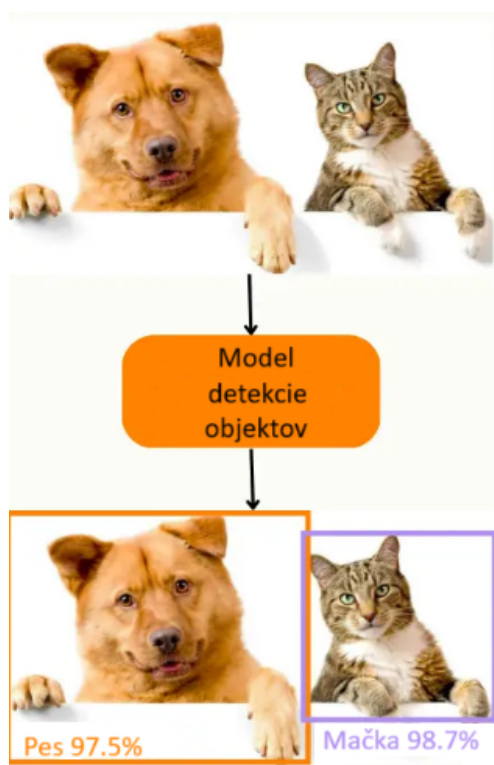
Pod názvom klasifikácia objektov môžeme chápať úlohu, ktorá identifikuje a kategorizuje objekty v obrázku s vopred definovanými triedami. Klasifikácia objektov je typicky vykonávaná technológiami strojového učenia, kde model je trénovaný na vybranej dátovej sade obrázkov a ich priradenie do označených tried. Trenovací model môže byť použitý na klasifikovanie nových obrázkov priradením označenia triedy na základe ich naučených vlastností. Použitie klasifikácie objektov je zahrnuté napr. pri rozpoznávaní dopravných značiek alebo identifikáciu rastliny na obrázku. [1]



Obrázok 2.1: Zrežazenie klasifikácie objektov

2.2 Detekcia objektov

Detekcia objektov je z pohľadu počítača úloha, ktorá identifikuje a lokalizuje objekty na základe preddefinovaných triedach vo vstupných obrázkoch. S vývojom neurónových sietí, detekcia objektov dosiahla veľmi sľubné výsledky. Existuje pár modelov a algoritmov ako sú R-CNN, Faster R-CNN, YOLO a SSD, ktoré boli vyvinuté na detekciu objektov. Tieto algoritmy a modely sa používajú v rôznych aplikáciách, ako je samojazdiace autá, sledovacie systémy a sledovanie objektov.



Obrázok 2.2: Zreťazenie detekcie objektov

2.3 YOLO

YOLO (You Only Look Once) je algoritmus detekcie objektov v reálnom čase, vyvinutý v roku 2015 dvojicou autorov Joseph Redmon a Ali Farhadi. Ide o jednostupňový detektor objektov, ktorý využíva konvolučnú neurónovú sieť (CNN) na prepovedanie ohraničujúcich políčok a prevdepodobností tried objektov vo vstupných obrázkoch.

Algoritmus YOLO rozdeľuje vstupný obrázok na mriežku buniek a pre každú bunku predpovedá pravdepodobnosť prítomnosti objektu a súradnice ohraničujúceho rámčeka objektu a predpovedá tiež triedu objektu. Na rozdiel od dvojstupňových detektorov objektov, ako je R-CNN a jeho variantov, YOLO spracováva celý obraz v jednom priechode, vďaka čomu je rýchlejší a efektívnejší.

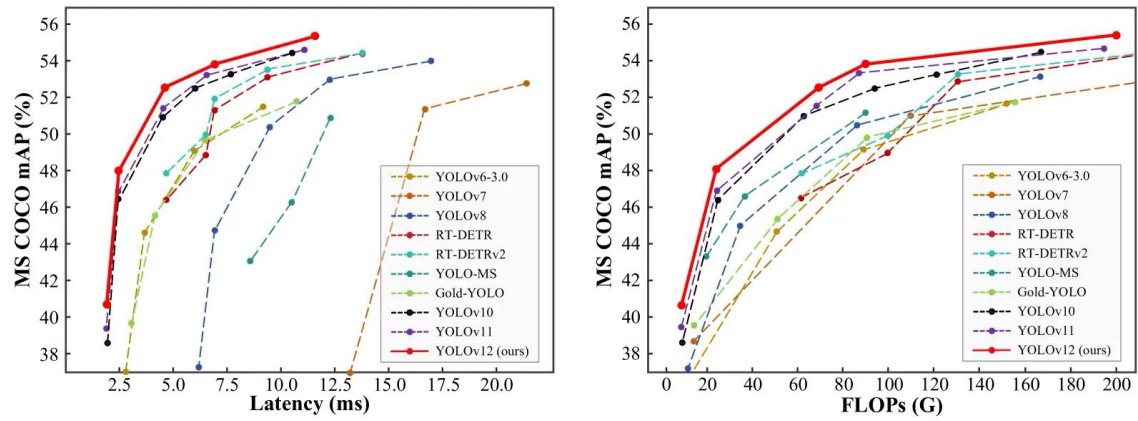
YOLO bolo vyvinuté v niekoľkých verziách od YOLOv1 až po najnovšie YOLOv12. Každá verzia bola postavená na predchádzajúcej verzii s vylepšenými funkciami, ako je vylepšená presnosť, rýchlejšie spracovanie a lepšia manipulácia s malými predmetmi.

YOLO je široko používaný v rôznych aplikáciach, ako sú samoriadiace autá a sledovacie systémy. Je tiež široko používaný na úlohy detekcie objektov v reálnom čase, ako je analýza videa v reálnom čase a video dohľad v reálnom čase.

Princíp YOLO algoritmu

Výhody YOLO algoritmu

Nevýhody YOLO algoritmu



Obrázok 2.3: Porovnanie s ďalšími známymi metódami pokiaľ ide o kompromisy latencie-presnosť (vľavo) a FLOP-presnosť (vpravo)

3 Vyhodnotenie

4 Záver

Zoznam použitej literatúry

1. MIRKHAN, Asmaa. *YOLO Algorithm: Real-Time Object Detection from A to Z*. YOLO Algorithm: Real-Time Object Detection from A to Z, 2023. Tech. spr. Kili.